

## 深蓝学院 VIO 课程第三课作业

1 样例代码给出了使用 LM 算法来估计曲线  $y = \exp(ax^2 + bx + c)$  参数  $a, b, c$  的完整过程。

- ① 请绘制样例代码中 LM 阻尼因子  $\mu$  随着迭代变化的曲线图
- ② 将曲线函数改成  $y = ax^2 + bx + c$ ，请修改样例代码中残差计算，雅克比计算等函数，完成曲线参数估计。
- ③ 如果有实现其他阻尼因子更新策略可加分（选做）。

2 公式推导，根据课程知识，完成 F, G 中如下两项的推导过程：

$$\mathbf{f}_{15} = \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta \mathbf{b}_k^g} = -\frac{1}{4}(\mathbf{R}_{b_i b_{k+1}}[(\mathbf{a}^{b_k} - \mathbf{b}_k^a)] \times \delta t^2)(-\delta t)$$

$$\mathbf{g}_{12} = \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \mathbf{n}_k^g} = -\frac{1}{4}(\mathbf{R}_{b_i b_{k+1}}[(\mathbf{a}^{b_k} - \mathbf{b}_k^a)] \times \delta t^2)(\frac{1}{2}\delta t)$$

3 证明式(9)。

### 1.1 绘制 LM 阻尼因子随迭代变化的曲线图

修改 CurveFitting\_LM 项目的 problem.h 和 problem.cc 源码，在 Problem::Solve() 函数中添加记录阻尼因子  $\mu$  的代码，执行后会写入一个 txt 文件中（见附件 1.1-lambdas.txt）。撰写一个脚本（见附件源码 scripts/drawIterations.py）绘制阻尼因子  $\mu$  随迭代次数变化的图，见图 1：

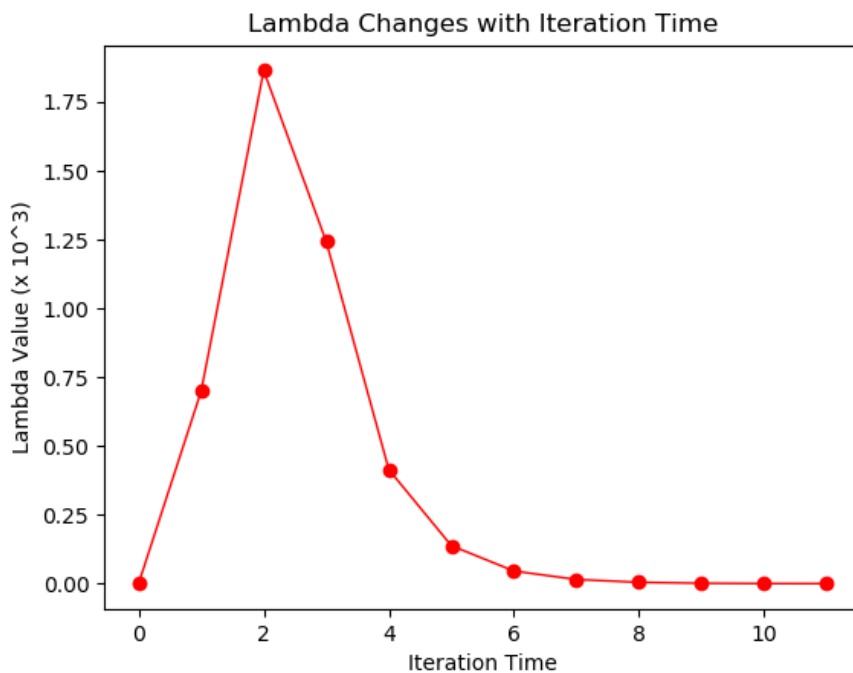


图 1 阻尼因子  $\mu$  随迭代次数变化曲线图

## 1.2 修改曲线函数，完成代码中残差计算和曲线参数估计

新的曲线函数：  $y = ax^2 + bx + c$

观测值受噪声影响：  $y_m = ax^2 + bx + c + noise$

残差计算：  $residual = ax^2 + bx + c - y_m$

残差对变量的雅克比：  $J = \begin{bmatrix} \frac{\partial r}{\partial a} & \frac{\partial r}{\partial b} & \frac{\partial r}{\partial c} \end{bmatrix} = [x^2 \quad x \quad 1]$

部分修改的代码如下图：

```

21 // 误差模型 模板参数: 观测值维度, 类型, 连接顶点类型
22 class CurveFittingEdge: public Edge
23 {
24 public:
25     EIGEN_MAKE_ALIGNED_OPERATOR_NEW
26     CurveFittingEdge(double x, double y): Edge(1, 1, std::vector<std::string>{"abc"}) {
27         x_ = x;
28         y_ = y;
29     }
30     // 计算曲线模型误差
31     virtual void ComputeResidual() override
32     {
33         Vec3 abc = vertices_[0]->Parameters(); // 估计的参数
34         residual_(0) = abc(0)*x_*x_ + abc(1)*x_ + abc(2) - y_; // 构建残差
35     }
36
37     // 计算残差对变量的雅克比
38     virtual void ComputeJacobians() override
39     {
40         Vec3 abc = vertices_[0]->Parameters();
41         double exp_y = std::exp( abc(0)*x_*x_ + abc(1)*x_ + abc(2) );
42
43         Eigen::Matrix<double, 1, 3> jaco_abc; // 误差为1维, 状态量 3 个, 所以是 1x3 的雅克比矩阵
44         jaco_abc << x_*x_, x_, 1;
45         jacobians_[0] = jaco_abc;
46     }
47     /// 返回边的类型信息
48     virtual std::string TypeInfo() const override { return "CurveFittingEdge"; }
49 public:
50     double x_, y_; // x 值, y 值为 _measurement
51 };
52
53 void write2txt(const std::vector<double>& data) {
54     ofstream ofs("lambdas2.txt");
55     for (size_t i=0; i<data.size(); ++i) {
56         ofs << data[i] << endl;
57     }
58     ofs.close();
59 }

```

图 2 新曲线模型的残差和雅克比计算代码

完整代码见附件源码 app/CurveFitting2.cpp，多次运行结果输出详情可见附件 1.2-runing\_log.txt 文件，这里整理成表格：

表 1 不同观测点数下新曲线模型的参数估计结果

观测点数	迭代次数	耗时(ms)	计算值	真实值
100	2	1.913	[1.610, 1.618, 0.995]	[1.0 ,2.0, 1.0]
500	3	14.604	[1.014, 1.936, 1.025]	
700	3	19.200	[1.001, 1.989, 0.989]	
1000	4	36.508	[1.000, 2.006, 0.969]	

### 1.3 其他阻尼因子的更新策略

查阅资料<sup>1</sup>，阻尼因子  $\mu$  的更新策略除了 g2o 和 ceres 采用的 Nielsen 策略外，还有另外两种常用的更新策略：

第一种策略<sup>2</sup>：

$$\mu_{i+1} = \begin{cases} \max(\frac{\mu_i}{L_{\downarrow}}, 10^{-7}) & \rho > 0 \\ \min(\mu_i L_{\uparrow}, 10^7) & \rho \leq 0 \end{cases}$$

第二种策略较为复杂：

$$\mu_{i+1} = \begin{cases} \max(\frac{\mu_i}{1 + \alpha}, 10^{-7}) & \rho(\alpha \Delta x) > 0 \\ \mu_i + |F(x + \Delta x) - F(x)| / (2\alpha) & \rho(\alpha \Delta x) \leq 0 \end{cases}$$

其中

$$\alpha = \frac{(J^T b)^T \Delta x}{\frac{F(x + \Delta x) - F(x)}{2} - 2(J^T b)^T \Delta x}$$

这里在 backend/problem.cc 文件中实现了另外的第一种更新策略，见下图。

```

358 bool Problem::IsGoodStepInLM2() {
359     double scale = 0;
360     scale = 0.5 * delta_x_.transpose() * (currentLambda_ * delta_x_ + b_);
361     scale += 1e-3; // make sure it's non-zero :)
362
363     // recompute residuals after update state
364     // 统计所有的残差
365     double tempChi = 0.0;
366     for (auto edge: edges_) {
367         edge.second->ComputeResidual();
368         tempChi += edge.second->Chi2();
369     }
370     double rho = (currentChi_ - tempChi) / scale;
371
372     if (rho > 0 && isfinite(tempChi)) // last step was good, 误差在下降
373     {
374         currentLambda_ = max(currentLambda_ / 4., 1.0e-7); // L_down = 4
375         currentChi_ = tempChi;
376         return true;
377     } else {
378         currentLambda_ = min(currentLambda_ * 6., 1.0e7); // L_up = 6
379         return false;
380     }
381 }
382 }
383
384 // namespace backend
385 // namespace myslam

```

图 3 新的阻尼因子  $\mu$  更新策略源码

1 Henri P Gavin. The Levenberg-Marquardt algorithm for nonlinear least squares curve-fitting problems. Duke University, 2019.

2 D.W. Marquardt. "An algorithm for least-squares estimation of nonlinear parameters," Journal of the Society for Industrial and Applied Mathematics, 11(2):431-441, 1963.

## 2. 证明公式 $f_{15}$ 和 $g_{12}$

$f_{15}$ 为位置预计分量 ( $\alpha_{b_i b_{k+1}}$ ) 对  $k$  时刻角速度 bias ( $b_k^g$ ) 的 Jacobian, 参考课件中 $f_{35}$ 的推导公式和已知条件有:

$$\alpha_{b_i b_{k+1}} = \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{2} a \delta t^2 \quad (1)$$

$$\omega = \frac{1}{2} \left( (\omega^{b_k} + \textcolor{blue}{n}_k^g - \textcolor{red}{b}_k^g) + (\omega^{b_{k+1}} + n_{k+1}^g - \textcolor{red}{b}_k^g) \right) \quad (2)$$

其中

$$\begin{aligned} a &= \frac{1}{2} \left( q_{b_i b_k} (a^{b_k} + n_k^a - b_k^a) + q_{b_i b_{k+1}} (a^{b_{k+1}} + n_{k+1}^a - b_k^a) \right) \\ &= \frac{1}{2} \left( q_{b_i b_k} (a^{b_k} + n_k^a - b_k^a) + q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \delta t \end{bmatrix} (a^{b_{k+1}} + n_{k+1}^a - b_k^a) \right) \end{aligned} \quad (3)$$

可知 $f_{15}$ 只与式(2)(3)中红色部分有关。由于噪声 $n_{k+1}^a$ 无法测得, 实际计算时用测量值代替, 可以忽略, 则有:

$$\begin{aligned} f_{15} &= \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta b_k^g} = \frac{\partial \frac{1}{2} a \delta t^2}{\partial \delta b_k^g} \\ &= \frac{1}{4} \frac{\partial q_{b_i b_{k+1}} (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\ &= \frac{1}{4} \frac{\partial q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \delta t \end{bmatrix} \otimes \begin{bmatrix} 1 \\ -\frac{1}{2} \delta b_k^g \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\ &= \frac{1}{4} \frac{\partial R_{b_i b_{k+1}} \exp \left( [-\delta b_k^g \delta t]_{\times} \right) (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\ &= \frac{1}{4} \frac{\partial R_{b_i b_{k+1}} \left( I + [-\delta b_k^g \delta t]_{\times} \right) (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\ &= -\frac{1}{4} \frac{\partial R_{b_i b_{k+1}} [(a^{b_{k+1}} - b_k^a) \delta t^2]_{\times} (-\delta b_k^g \delta t)}{\partial \delta b_k^g} \\ &= -\frac{1}{4} R_{b_i b_{k+1}} [(a^{b_{k+1}} - b_k^a)_{\times} \delta t^2] (-\delta t) \end{aligned} \quad (4)$$

同理，对于  $g_{12}$  来说只与式(2)蓝色部分有关，则：

$$\begin{aligned}
 g_{12} &= \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta n_k^g} = \frac{\partial \frac{1}{2} a \delta t^2}{\partial \delta n_k^g} \\
 &= \frac{\frac{1}{4} \frac{\partial q_{b_i b_k}}{\partial \delta n_k^g} \otimes \left[ \frac{1}{2} \omega \delta t \right] \otimes \left[ \frac{1}{4} \delta n_k^g \delta t \right] (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta n_k^g} \\
 &= \frac{\frac{1}{4} \frac{\partial R_{b_i b_{k+1}}}{\partial \delta n_k^g} \left( I + \left[ \frac{1}{2} \delta n_k^g \delta t \right]_{\times} \right) (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta n_k^g} \\
 &= -\frac{\frac{1}{4} \frac{\partial R_{b_i b_{k+1}}}{\partial \delta n_k^g} [(a^{b_{k+1}} - b_k^a) \delta t^2]_{\times} \left( \frac{1}{2} \delta n_k^g \delta t \right)}{\partial \delta n_k^g} = \\
 &= -\frac{1}{4} R_{b_i b_{k+1}} ([ (a^{b_{k+1}} - b_k^a) ]_{\times} \delta t^2) \left( \frac{1}{2} \delta t \right)
 \end{aligned} \tag{5}$$

得证。

### 3. 证明下式

$$\Delta \mathbf{x}_{lm} = - \sum_{j=1}^n \frac{\mathbf{v}_j^T \mathbf{F}'^T}{\lambda_j + \mu} \mathbf{v}_j$$

由课件公式已知：

$$(\mathbf{J}^T \mathbf{J} + \mu \mathbf{I}) \Delta \mathbf{x} = -\mathbf{J}^T \mathbf{f} = -\mathbf{F}'^T \tag{6}$$

$$\mathbf{J}^T \mathbf{J} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T \tag{7}$$

其中  $\mathbf{J}^T \mathbf{J}$  半正定，其特征值和对应的特征向量为  $\{\lambda_j\}, \{\mathbf{v}_j\}$ 。因为  $\mathbf{V}$  正交，所以有：

$$v_i^T v_j = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases} \tag{8}$$

参考《非线性最小二乘解法 第2版》<sup>3</sup>的证明过程，由公式（6）至（8）有：

$$\mathbf{J}^T \mathbf{J} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T = \sum_{j=1}^n \lambda_j \mathbf{v}_j \mathbf{v}_j^T \tag{9}$$

<sup>3</sup> K. Madsen, H.B. Nielsen, O. METHODS FOR NON-LINEAR LEAST SQUARES PROBLEMS. Tingleff Informatics and Mathematical Modellin. 2nd Edition, April 2004.

$$\mathbf{J}^T \mathbf{J} \mathbf{v}_j = \lambda_j \mathbf{v}_j \quad (10)$$

令

$$-\mathbf{F}'^T = \sum_{j=1}^n \beta_j \mathbf{v}_j, \quad \Delta \mathbf{x} = \sum_{j=1}^n \eta_j \mathbf{v}_j \quad (11)$$

根据式 (9) 到 (11) 创造误差函数

$$\begin{aligned} r &= -\mathbf{F}'^T - (\mathbf{J}^T \mathbf{J} + \mu \mathbf{I}) \Delta \mathbf{x} \\ &= \sum_{j=1}^n \beta_j \mathbf{v}_j - (\mathbf{J}^T \mathbf{J} + \mu \mathbf{I}) \sum_{j=1}^n \eta_j \mathbf{v}_j \\ &= \sum_{j=1}^n (\beta_j \mathbf{v}_j - \lambda_j \eta_j \mathbf{v}_j - \mu \eta_j \mathbf{v}_j) \\ &= \sum_{j=1}^n [\beta_j - (\lambda_j + \mu) \eta_j] \mathbf{v}_j \end{aligned} \quad (12)$$

取其范数有：

$$\|r\|^2 = r^T r = \sum_{j=1}^n [\beta_j - (\lambda_j + \mu) \eta_j]^2 \quad (13)$$

当  $\beta_j = (\lambda_j + \mu) \eta_j$  时误差函数最小，此时有

$$\eta_j = \frac{\beta_j}{\lambda_j + \mu} \quad (14)$$

代入式 (11)， $\Delta \mathbf{x}$  可表示为：

$$\Delta \mathbf{x} = \sum_{j=1}^n \eta_j \mathbf{v}_j = \sum_{j=1}^n \frac{\beta_j}{\lambda_j + \mu} \mathbf{v}_j = - \sum_{j=1}^n \frac{\mathbf{v}_j^T \mathbf{F}'^T}{\lambda_j + \mu} \mathbf{v}_j \quad (15)$$

证毕。